

Universidade Federal de Minas Gerais
Escola de Engenharia
Curso de Graduação em Engenharia de Controle e Automação



**Aplicação de reconhecimento de padrões em dados de sensor
acelerômetro utilizando grafo geométrico em sistema de
microcontrolador embarcado**

Relatório 1 de Atividades PFC 1

Orientador: Vitor Angelo
Aluno: João Pedro Miranda Marques
Matrícula: 2017050495

10 de outubro de 2022

1 Resumo

Esse trabalho de projeto de final de curso se dedica à implementação do algoritmo de reconhecimento de padrões por meio de grafo geométrico, utilizando-se especificamente do Grafo de Gabriel.[1].

A aplicação será classificar movimentos de um objeto. Para isso faz-se o uso de uma placa de desenvolvimento do microcontrolador ESP32 e um sensor acelerômetro a ser escolhido. O protótipo desenvolvido deverá reconhecer qual movimento foi aplicado ao objeto e exercer uma atuação a partir disso.

No semestre anterior validamos o uso do algoritmo do grafo de Gabriel para a separação de regiões em duas dimensões. Para essa validação foi utilizado o exemplo de teste utilizado na própria documentação do grafo e obtivemos os mesmos resultados.

Nesse projeto a quantidade de dimensões a ser utilizada nas amostras de dados será maior. O grafo de Gabriel apresenta complexidade exponencial com relação a dimensão do dado de entrada. Por esse motivo a ideia é fazer o treinamento do grafo em um computador pessoal e implementa-lo no microcontrolador para fazer as devidas inferências.

2 Introdução

Nesta etapa do projeto fiz testes com dois sensores acelerômetros:

MMA8452 e MPU6050

Como resultado optei por utilizar o sensor MPU6050 por sua grande variedade de bibliotecas, baixo custo, 16 bits de resolução e, principalmente, por possuir sensor acelerômetro e giroscópio em um mesmo chip MEMS¹.

O Microcontrador ESP32 e o sensor acelerômetro foram colados em uma pequena caixa onde futuramente pode ser adicionado uma bateria. Podemos ve-lo na Figura 1.



Figura 1: Protótipo

3 Desenvolvimento

3.1 Análise visual

Foram recolhidos dados de amostra para:

- vibração nos eixos X, Y e Z
- movimento circular no eixo Z
- movimento de rotação em torno de um ponto fora do objeto no eixo Y. (Gira e volta)

A aquisição de dados foi feita num período de 50ms.

Nas figuras abaixo vemos os dados recolhidos. Em cada imagem temos 6 gráficos referentes respectivamente à aceleração 3 eixos e giroscópio nos 3 eixos. Podemos também ver que tivemos etapas de resolução do movimento e etapas de repouso.

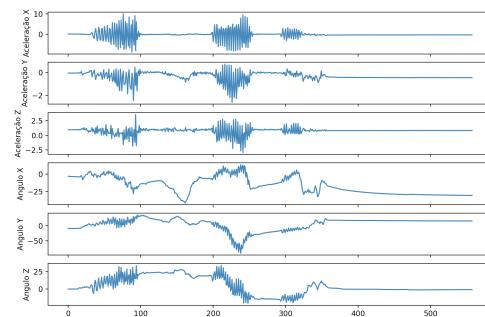


Figura 2: Vibração no eixo X

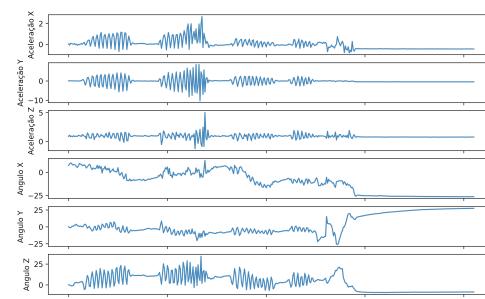


Figura 3: Vibração no eixo Y

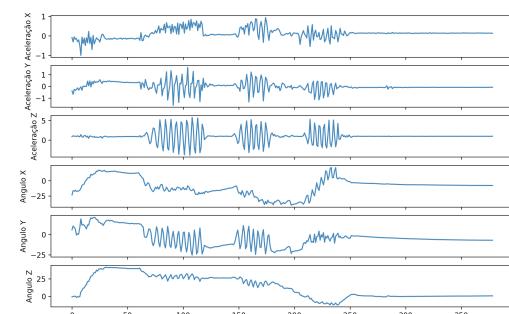


Figura 4: Vibração no eixo Z

¹MEMS: Micro Eletro Mechanical System..

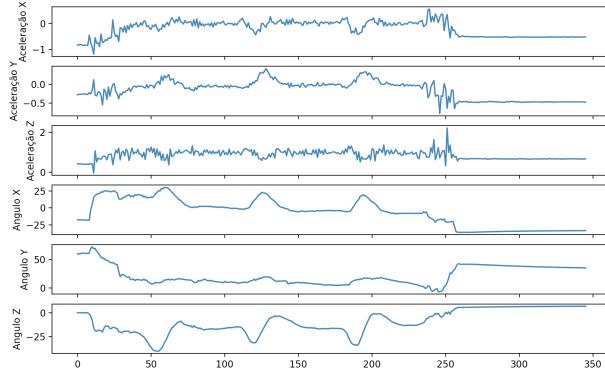


Figura 5: Movimento circular no eixo Z

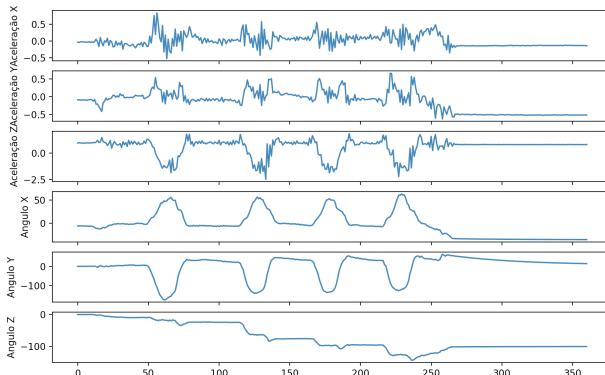


Figura 6: Gira e Volta no eixo Y

3.2 Tratamento dos dados recolhidos

Primeiramente foi classificado cada comportamento de curva de acordo com seu respectivo movimento associado.

Com isso resultamos com um arquivo csv onde cada linha é um valor amostrado no tempo e contendo as seguintes colunas:

- AccX (aceleração no eixo X)
- AccY (aceleração no eixo Y)
- AccZ (aceleração no eixo Z)
- AngX (rotação no eixo X)
- AngY (rotação no eixo Y)
- AngZ (rotação no eixo Z)
- Class (classificação do movimento)

Abaixo vemos uma amostra de cada tipo de movimento classificado.

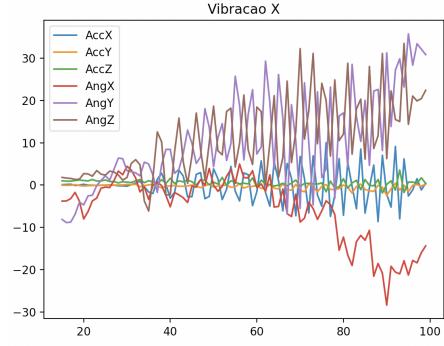


Figura 7: sample VibracaoX

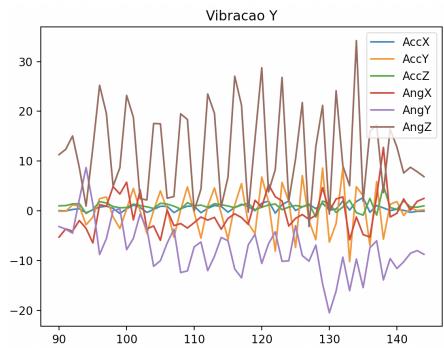


Figura 8: sample VibracaoY

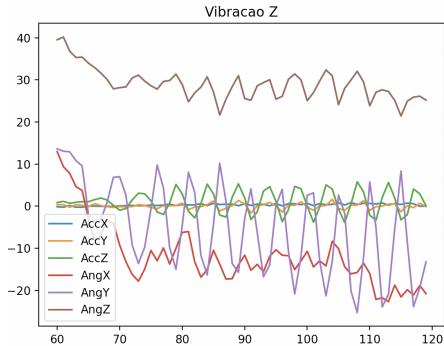


Figura 9: sample VibracaoZ

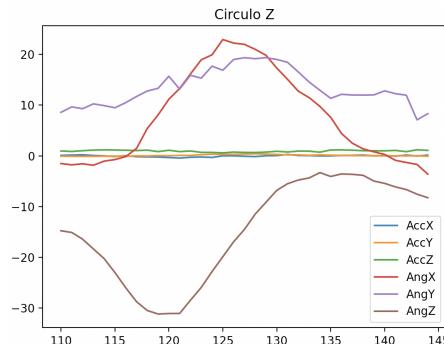


Figura 10: sample CirculoZ

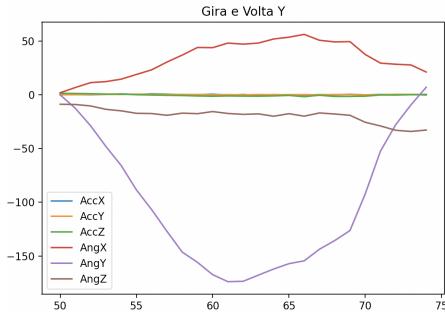


Figura 11: sample GiraeVoltaY

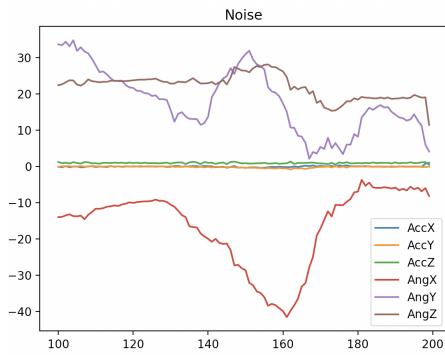


Figura 12: sample Noise

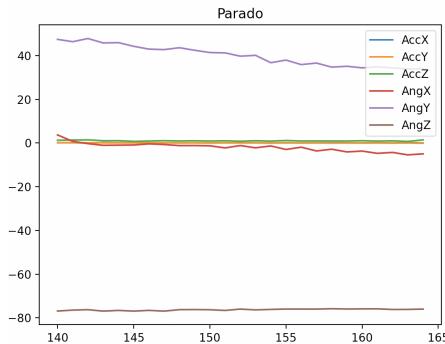


Figura 13: sample Parado

Analizando visualmente já podemos perceber que:

- sinais com maior amplitude alta e frequência alta tendem a ser movimentos de vibração. Definindo qual eixo temos uma amplitude maior que as demais sabemos qual eixo o movimento foi destinado.

- sinais com amplitude alta em baixas frequências tendem a ser movimento de envolvem rotação. Definindo o formato da onda conseguimos diferenciar movimento de GiraeVolta de movimentos de Circulo.

- Sinais estáveis definem se o objeto está parado. De acordo com seus valores também podemos saber a posição de repouso.

- Sinais ruidosos são bem comuns em sensores MEMS e por isso não podem ser associados à algum tipo de movimento.

²SMOTE: Synthetic Minority Oversampling Technique.

3.2 Análise estatística dos dados

Primeiramente analisei a distribuição de amostras que temos. Podemos ver no gráfico de Figura 14 que essa distribuição está desbalanceada. Temos mais amostras de movimento parado. Além disso temos poucos dados para fazer um modelo de inferências. Por esse motivo, mais dados serão gerados e classificados na próxima etapa. Além disso, podemos aplicar técnicas de Undersampling, Oversampling e SMOTE².

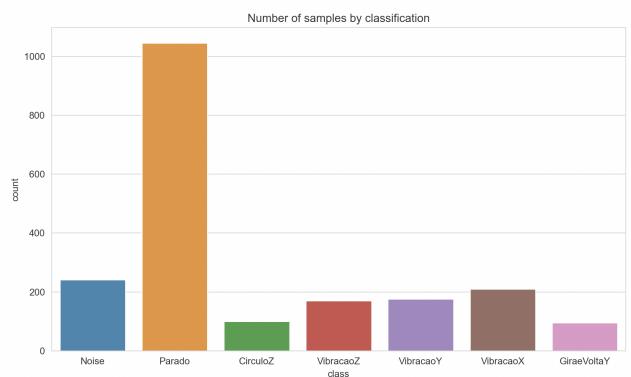


Figura 14: sample Distribution

Também foi realizado a distribuição de densidade dos dados em cada eixo do acelerômetro para todos os movimentos em questão.

As Figuras 15, 16 e 17 representam os dados recolhidos nos eixos do acelerômetro. Nasel vemos que o movimento de vibração nos eixos correspondentes apresentam dados mais distribuídos.

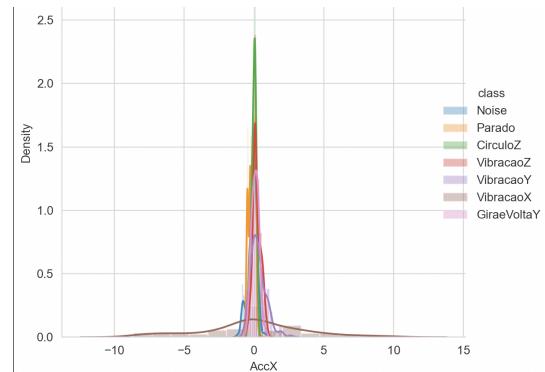


Figura 15: AccX distribution

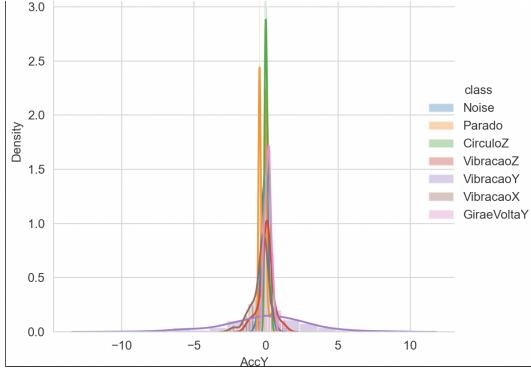


Figura 16: AccY distribution

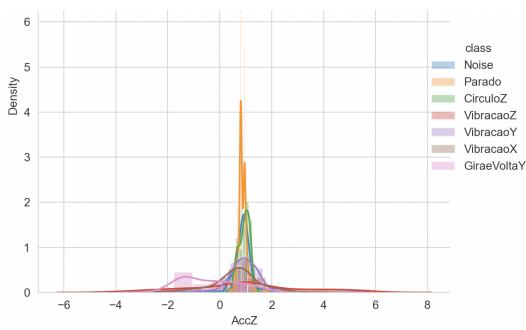


Figura 17: AccZ distribution

As Figuras 18, 19 e 20 representam os dados recolhidos nos eixos do giroscópio. Podemos ver que nos dados desse sensor temos maior separabilidade entre os movimentos de rotação.

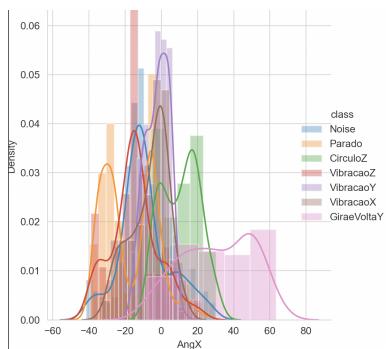


Figura 18: AngX distribution

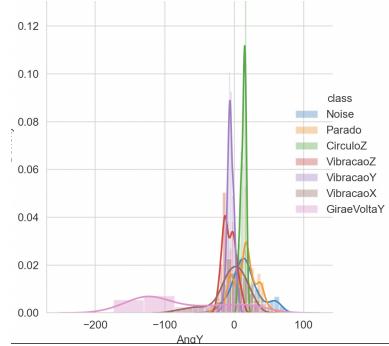


Figura 19: AngY distribution

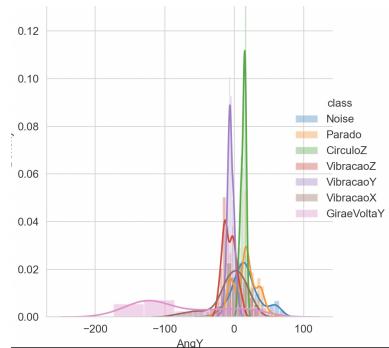


Figura 20: AngY distribution

3.3 Data Transformation

Nessa etapa os dados foram reorganizados em listas de janelas de tempo ("windowing"). Isso porque um movimento não consegue ser detectado com apenas as informações adquiridas em uma amostra de tempo, mas sim em uma janela de amostras. Por esse motivo foram agregados 50 amostras em uma lista de valores e sua respectiva classificação. Essa transformação foi implementada de forma não discreta entre os dados, ou seja, cada janela de tempo terá dados da janela de tempo anterior também.

4 Conclusões

Nessa etapa do projeto foi dedicado maior tempo para adquirir, tratar e estudar os dados do sensor MPU6050. Com isso estamos desenvolvendo uma engenharia de características de forma a abstrair as características mais úteis para a futura separabilidade dos dados.

Para as próximas etapas tenho o objetivo de já desenvolver algum mecanismo de classificação de movimentos com os dados adquiridos no sensor sendo importados para o computador e verificar a acurácia de classificação em tempo real.

Referências

- [1] Luiz C. B. Torres et al. “Large Margin Gaussian Mixture Classifier With a Gabriel Graph Geometric Representation of Data Set Structure”. Em: *IEEE Transactions on Neural Networks and Learning Systems* 32.3 (mar. de 2021), pp. 1400–1406. ISSN: 2162-2388. DOI: [10.1109/TNNLS.2020.2980559](https://doi.org/10.1109/TNNLS.2020.2980559).